

HealthSearch — Motor de Busca Médica Híbrido

Integrantes: Igor Nunes Moneta; Josenilton Cirne Ramalho Neto; Pedro Henrique Alves Vieira do Nascimento.

1. Arquitetura da solução

O sistema recebe uma consulta médica, aplica tokenização e limpeza em português (minúsculas, remoção de caracteres especiais e stopwords) e envia a consulta para dois motores independentes. O primeiro utiliza BM25 para correspondência lexical. O segundo utiliza embeddings do modelo *paraphrase-multilingual-MiniLM-L12-v2* e similaridade de cosseno. Quando o modelo não está disponível, o código utiliza uma simulação vetorial documentada baseada em grupos de termos relacionados. Os dois rankings são combinados pelo Reciprocal Rank Fusion (RRF).

2. BM25 e parâmetros iterativos

Os parâmetros são controlados pela Sidebar: **k** varia de 0,0 a 3,0 com padrão 1,2; **b** varia de 0,0 a 1,0 com padrão 0,75. A alteração dos sliders recalcula o ranking lexical. O BM25 é executado por meio da biblioteca rank-bm25.

3. Busca semântica

Cada documento e a consulta são mapeados para vetores. A similaridade de cosseno é usada para comparar a proximidade entre a consulta e cada documento, permitindo recuperar relações de significado além da correspondência literal de palavras.


4. Fusão RRF

A pontuação híbrida utiliza $k_{RRF} = 60$ e o peso α entre 0,0 e 1,0:

$$\text{Score_RRF}(D) = \alpha / (60 + \text{Rank_BM25}) + (1 - \alpha) / (60 + \text{Rank_Semântico})$$

Quanto maior o score RRF, maior a posição final do documento no ranking híbrido.

5. Gráfico de comparação de ranks



Exemplo ilustrativo de comparação das posições. O gráfico mostra como os motores lexical e semântico podem produzir ordens diferentes e como o RRF consolida essas posições.

6. Interface e organização

A aplicação Streamlit é organizada em quatro abas: **Léxico**, com o ranking BM25; **Semântico**, com os scores de similaridade; **Híbrido RRF**, com o ranking final; e **Matriz Comparativa**, que apresenta as posições de cada documento nos três métodos.

Função	Responsabilidade
limpar_texto()	Normalização, remoção de caracteres e stopwords.
calcular_bm25()	Busca lexical e aplicação de k e b .
buscar_semantico()	Embeddings/simulação vetorial e similaridade.
calcular_rrf()	Fusão dos rankings com α e $kRRF = 60$.

7. Corpus e fluxo de processamento

O corpus contém seis diretrizes técnicas sobre emergência cardíaca, farmacologia, hipertensão, AVC, reanimação e procedimentos de UTI. O fluxo é: corpus → pré-processamento → BM25 e embeddings → rankings independentes → RRF → ranking híbrido.

8. Divisão da equipe

Josenilton Cirne Ramalho Neto: pré-processamento do corpus, limpeza de texto, tokenização e preparação dos dados para o BM25.
Pedro Henrique Alves Vieira do Nascimento: implementação e ajuste do BM25, busca semântica, similaridade de cosseno e integração dos rankings.
Igor Nunes Moneta: implementação da interface Streamlit, RRF, matriz comparativa, testes e organização da documentação.

9. Tecnologias

Python, Streamlit, Pandas, rank-bm25 e Sentence Transformers. O código também possui fallback de simulação vetorial para manter a aplicação executável quando o modelo semântico não puder ser carregado.

10. Conclusão

O HealthSearch integra recuperação lexical, busca semântica e fusão de rankings em uma única interface. A arquitetura separa os motores de busca e utiliza o RRF para produzir uma resposta híbrida configurável pelo usuário.